

Rheinisch-Westfälische Technische Hochschule Aachen  
Lehrstuhl für Informatik 6  
Prof. Dr.-Ing. Hermann Ney

Seminar Selected Topics in Human Language Technology and Pattern Recognition im SS  
2016

# **Attention-based Neural Machine Translation**

*Derui ZHU*

Matrikelnummer 352273

Betreuer: Parnia Bahar



## Inhaltsverzeichnis

<b>1</b>	<b>Introduction</b>	<b>5</b>
1.1	Rule-based Translation . . . . .	5
1.2	Stastical-based Translation . . . . .	5
1.3	Neural Network-based Translation . . . . .	6
1.4	Matrices on translation performance . . . . .	7
<b>2</b>	<b>Neural Network</b>	<b>7</b>
<b>3</b>	<b>Neural Machine Translation</b>	<b>7</b>
<b>4</b>	<b>Attention-based Neural Machine Translation</b>	<b>7</b>
<b>5</b>	<b>Evaluation</b>	<b>7</b>
<b>6</b>	<b>Introduction</b>	<b>7</b>
<b>7</b>	<b>Neural Network</b>	<b>8</b>
7.1	Unterabschnitt . . . . .	8
<b>8</b>	<b>Neural Machine Translation</b>	<b>8</b>
<b>9</b>	<b>Attention-based Neural Machine Translation</b>	<b>8</b>
9.0.1	Unter-Unterabschnitt: Beispiel für Tabellen . . . . .	8
9.1	Unterabschnitt: Beispiel für Grafiken . . . . .	8
<b>10</b>	<b>Evaluation</b>	<b>10</b>
	<b>Literaturverzeichnis</b>	<b>10</b>

## Tabellenverzeichnis

1	Beispiel Tabelle . . . . .	8
---	----------------------------	---

## Abbildungsverzeichnis

1	Example of rule-based translation process . . . . .	5
2	string-based and tree-based translation models . . . . .	6
3	The compare between phrase-based model(a) and hierarchical phrase-based model . . . . .	6
4	Sequence to sequence Tranlation . . . . .	7
5	Architektur eines Spracherkennungssystems . . . . .	9



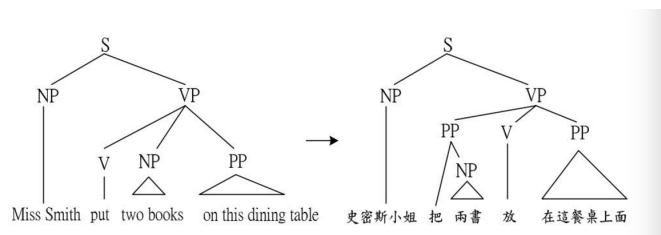


Abbildung 1: Example of rule-based translation process

## 1 Introduction

Machine translation is one important research field of natural language processing. In general, machine translation is the process of transferring one natural language into another natural language. From early lexicon translation to corpus-based statistical translation, machine translation technologies experience a huge improvement.

Recalling the history of machine translation development, before 1980s, rule-based translation were the most important approaches. In the end of 1980s, statistical translation approaches were proposed, the situation changed. It rapidly becomes mainstream approaches. Recently, neural network-based translation has shown its huge power.

### 1.1 Rule-based Translation

Rule-based translation is a process that generate target language by analysing source language's structure and building a meaningful representation. Rule-based approaches are mainly divided into transfer-based and interlingua-based translation process. Interlingua-based approach generate intermediate language first after analysing source language. Then the target language is produced by the intermediate language. Most of the rule-based translation system uses transfer-based translation process. It is composed of three steps. Firstly, the system generates an abstract representation of source language. Then, the abstract representation of source language is transferred into the abstraction representation of target language. In the end, the abstraction representation of target language generates target language.

For example, we consider to translate the english sentence "Miss Smith put two books on this dining table" into chinese. First of all, the system praser its morphological syntax to get the syntax tree(below [2]). During the transfer phase, lexical and syntax transform are excuted at the same time. After that, we get the target words, which locate in the nodes of syntax tree generated.

### 1.2 Stastical-based Translation

The basic idea of statistical approach is to obtain translation rules and probability parameters automatically from bilingual corpus by employing statistical machine learning technologies. Graphic 1 shows string-based and tree-based translation model, which are used in statistical translation widely. Statistical translation models usually is partitioned as word-based, phrase-based and gramma-based translation model. Phrase-based translation model is a mature tranlation approach. The phrase means successive word sequences rather than the phrase defined in linguistics. The main idea of this model is to extract

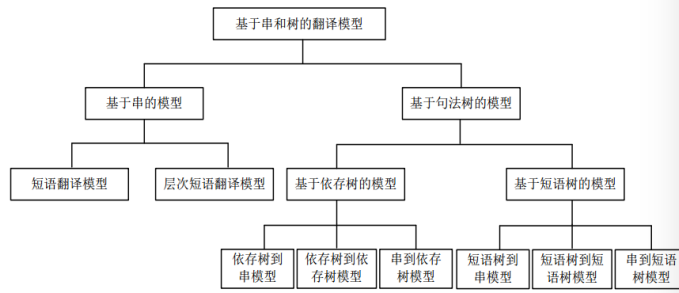


Abbildung 2: string-based and tree-based translation models

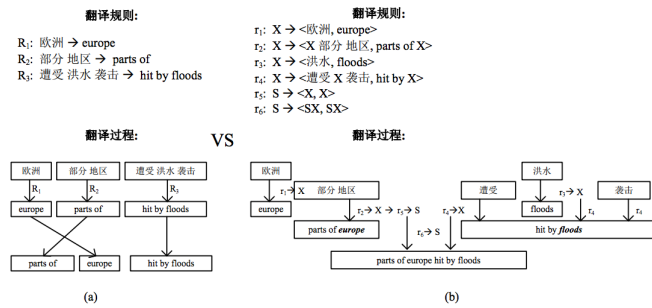


Abbildung 3: The compare between phrase-based model(a) and hierarchical phrase-based model

phrase-to-phrase translation rules from large number of bilingual sentences. Then, in the phase of translation, system cuts the words to translate according to the phrases that got by last step. By the help of re-order model, finally, target sentence is generated. If there is variables in the phrase contained into translation rules, the phrase-based model is hierarchical phrase-based translation model. It owns better representation ability and performance. The below graph 3 show the comparative between these two models.

### 1.3 Neural Network-based Translation

Neural network-based translation approach is proposed recently. Based on the sequence to sequence learning, neural machine translation does not rely on the specialized knowledge on language, like grammar, syntax, sentence structure and so on. Traditional statistical machine translation has much dependency on sub model, for example, rescoring model and reorder model. Compared to that, neural machine translation is much easier. However, the complexity of training neural translation model is harder than statistical translation model.

As shown in the graph 4, neural translation process is divided into two steps, encoder and decoder. In the phase of encode, it encodes the source sentence into a vector that contains source sentence information. Then, the decoder generate the target sentence based on the vector.




Abbildung 4: Sequence to sequence Translation

## 1.4 Metrics on translation performance

This part, I will introduce the metrics on translation.

This paper will be organized as 4 parts in the rest sections. The second part will give a brief introduction on neural network, which can be used in sequence-to-sequence learning. It is the foundation of neural machine translation. Next, the third part will propose a classical neural machine translation model. Then, the attention-based neural machine translation will be shown. In the last part, we will show the experiment result between these machine translation model in terms of Bleu scores.

## 2 Neural Network

## 3 Neural Machine Translation

## 4 Attention-based Neural Machine Translation

## 5 Evaluation

## 6 Introduction

Dies ist eine Referenz auf Abschnitt 6

Erzeugen wir erst etwas Text, um uns mit der Schreibweise in  $\text{\LaTeX}$  vertraut zu machen.  $\text{\LaTeX}$  bricht selbständig Zeilen und Seiten um. Selbst in einem Neologismus wie dem ziemlich langen Wort aus Michael Endes zuletzt geschriebenem Buch „Der satanarchäolügenialkohöllische Wunschpunsch“ findet  $\text{\LaTeX}$  eine gute Trennstelle. Manchmal ist es aber sinnvoll, selber eine Trennstelle vorzugeben. Dies gibt man mit `\-` im Wort im  $\text{\TeX}$ -File selbst an, also z.B. Trenn`\-`stelle.

Lässt man eine Zeile im  $\text{\TeX}$ -File frei so wird automatisch die nächste Zeile eingerückt. Wem das nicht gefällt, der kann im  $\text{\TeX}$ -File den Befehl `\parindent0pt` auskommentieren und das damit unterdrücken. Text mit ä, ö, Ü, Straße, Café.

Dies ist ein laufender-Text mit Einsteins Formel  $E = m \cdot c^2$ .

Tabelle 1: Beispiel Tabelle

links	zentriert	rechts
links2	zentriert2	rechts2
XXXXXXXXXXXXX	XXXXXXXXXXXXXXXXXXXXXXXXXXXXX	XXXXXXXXXXXXX

Eine etwas kompliziertere Formel:

$$a \frac{1 - q^{n+1}}{1 - q} = \sum_{i=0}^n a q^i \quad \text{mit} \quad a, q \in \mathcal{R}, q \neq 1$$

Nun folgt die Bayessche Entscheidungsregel:

$$r(X) = \operatorname{argmax}_{w_1 \dots w_N} \left\{ Pr(w_1^N | x_1^T) \right\} \quad \text{mit} \quad Pr(w_1^N | x_1^T) = \frac{Pr(x_1^T | w_1^N) \cdot Pr(w_1^N)}{Pr(x_1^T)} \quad . \quad (1)$$

Beispiel für ein lineares Gleichungssystem:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 &= y_1 \\ a_{21}x_1 + a_{22}x_2 &= y_2 \\ a_{31}x_1 &= y_3 \end{aligned}$$

## 7 Neural Network

### 7.1 Unterabschnitt

## 8 Neural Machine Translation

## 9 Attention-based Neural Machine Translation

### 9.0.1 Unter-Unterabschnitt: Beispiel für Tabellen

In der Umgebung zum Plazieren von Tabellen (und auch Grafiken) kann man optional die Werte t, b, h und H verwenden. Damit lassen sich Tabellen am oberen Rand (top), unten (bottom) und an der aktuellen Position (here) plazieren. Je nach Seitenlayout funktioniert die Angabe h nicht immer. Mittels H lässt sich dann die aktuelle Position erzwingen.

### 9.1 Unterabschnitt: Beispiel für Grafiken

Grafiken werden üblicherweise mit dem (frei verfügbaren) Programm tgif erstellt. Alternativ hierzu lässt sich auch das Programm xfig verwenden. tgif ist zwar nicht ganz einfach zu bedienen, stellt dem (erfahrenen) Anwender aber wesentlich mehr Möglichkeiten zur



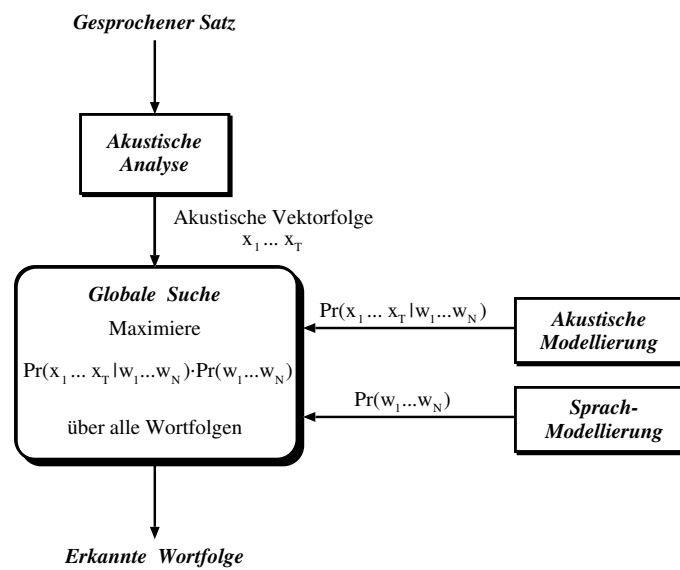


Abbildung 5: Architektur eines Spracherkennungssystems

Gestaltung von Grafiken zur Verfügung. Die Konvertierung der \*.obj Dateien nach encapsulated PostScript erfolgt über die Kommandozeile mit

```
tgif -print -eps <Datei>.obj
```

Nun erzeugen wir mittels  $\text{BIB}\text{T}_{\text{E}}\text{X}$  eine Literaturliste. Dazu erzeugen wir uns ein File namens `<Dateiname>.bib`, dass denselben Dateinamen wie unser  $\text{T}_{\text{E}}\text{X}$ -File hat. Dieses wird dann mit

`bibtex <Dateiname>`

compiliert. Die im laufenden Text vorkommenden symbolischen Literaturverweise zeigen dann auf den entsprechenden Eintrag im Literaturverzeichnis. Dies geschieht mit dem Befehl `\cite{}`. Das sieht dann z.B. wie folgt aus.

Zitat aus [1], Zitat aus [3], Zitat aus [2]. Wichtig ist, dass zuerst das  $\text{T}_{\text{E}}\text{X}$ -File compiliert wird und dann das  $\text{BIB}\text{T}_{\text{E}}\text{X}$ -File. Da sich dann die Referenzen meist ändern, ist ein erneutes Compilieren des  $\text{T}_{\text{E}}\text{X}$ -Files notwendig.

Es gibt zahlreiche style-files, mit denen man das Layout eines Literaturverzeichnisses ändern und die Darstellung der Literatur-Referenzen modifizieren kann.

Letzter Hinweis:  $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ -Neulinge sollten auch die Kommentare im  $\text{T}_{\text{E}}\text{X}$ -File lesen.

## 10 Evaluation

### Literatur

- [1] Autor1, Autor2, and Autor3. Titel des Papers. In *Name des Bandes, in dem Artikel veröffentlicht wurde*, volume Band, pages xxx–yyy, Monat 1991.
- [2] Autor1, Autor2, and Autor3. Titel des Reports. Technical report, Name des Instituts, Monat 1996.
- [3] M. Ende. *Der Wunschpunsch*. Tiemann Verlag, 1989.